

Conocimiento en el aprendizaje

Universidad Mayor de San Simón

Inteligencia Artificial II

Jose Enrique Camacho Silvestre Alexander Mamani Yucra
Rudy Walter Martinez Melgarejo

26 de mayo de 2020

1 Antecedentes

Antes de poder explicar los distintos de métodos de aprendizaje es necesario poseer conocimientos previos de algunos conceptos, el objetivo de esta sección es presentarlos de manera superficial.

1.1 Aprendizaje inductivo

En nuestro enfoque definimos una función como un conjunto de pares ordenados.

Sea f una función $f : \mathbb{R} \mapsto \mathbb{R}$ y desconocida, $f(x)$ el valor de la función f en x , \mathcal{A} un conjunto tal que $\mathcal{A} \subseteq f$, devolver una función h denominada *hipótesis* que se aproxime a la función f a partir del conjunto \mathcal{A} .

Para este tipo de aprendizaje nos interesa pensar en una *hipótesis* como un polinomio $h := P(x)$. Un polinomio puede definirse de la siguiente manera:

$$\text{Sea } n \in \mathbb{N}, \text{ entonces } P_n(x) = \sum_{i=0}^n a_i x^i$$

H el conjunto de hipótesis a considerar denominado *espacio de hipótesis*:

$$\text{Sea } j, k \in \mathbb{N}, j \leq k, \text{ entonces } H = \{P_0(x), P_1(x), P_2(x), \dots, P_j(x)\}.$$

Consistencia, se dice que una hipótesis es consistente si verifica todos los puntos, es decir $\mathcal{A} \subset h$. Sin embargo pueden existir más de dos hipótesis consistentes, la solución a esto nos la da la *navaja de Ockham*, en donde nos sugiere elegir la hipótesis más sencilla.

Pueden existir hipótesis que no son consistentes sin embargo permiten hacer mejores predicciones, estas funciones realizan una buena generalización. Esto nos dice que existe la posibilidad de que la función f sea no determinística.

1.2 Conocimiento *a priori* y *a posteriori*

Tipos de conocimiento *a priori* (en latín: 'previo a') y *a posteriori* (en latín: 'posterior a'), estos se clasifican dependiendo el grado de dependencia que poseen con respecto a la experiencia.

El conocimiento o justificación *a priori* es independiente de la experiencia, es decir, que no se requiere de ninguna investigación para ser considerado como verdadero, solo basta con comprender el significado de los términos involucrados, por ejemplo: “Si Wilhelm II reinó al menos cuatro días, entonces reinó más de tres días.”

El conocimiento o justificación *a posteriori* depende de la experiencia, es decir, que se requirio de una observación previa para convencerse de que la proposición es verdadera, por ejemplo: “Wilhelm II reinó de 1888 a 1918” Esta proposition, si es cierta, se conoce como conocimiento *a posteriori* ya que es un hecho empírico que no se puede conocer simplemente por la razón.

2 Una formulación lógica del aprendizaje

Antes de nada debemos especificar la notación, definir algunos conceptos y recordar algunas ideas vistas en el capítulo anterior.

La lógica de predicados esta fuertemente inspirada en la idea de función matemática.

Un predicado es una expresión lingüística (ejem.: $EsHombre(socrates)$) que se puede conectar con una o varias otras expresiones para formar una oración o también llamada sentencia (ejem.: $EsHombre(socrates) \wedge EsHombre(platon) \wedge \dots$).

Para dar entender mejor el concepto de ejemplo recordemos la definición de ejemplo que nos brinda los árboles decisión booleano, donde un ejemplo consiste en un vector de atributos de entrada, X , y un único valor de salida booleano y , formalmente (X, y) .

Ejemplo	Atributos										Meta
	<i>Alt</i>	<i>Bar</i>	<i>Vier</i>	<i>Ham</i>	<i>Cientes</i>	<i>Precio</i>	<i>Llov</i>	<i>Res</i>	<i>Tipo</i>	<i>Est</i>	Esperar
X_1	<i>Sí</i>	<i>No</i>	<i>No</i>	<i>Sí</i>	<i>Algunos</i>	<i>\$\$\$</i>	<i>No</i>	<i>Sí</i>	<i>Francés</i>	<i>0-10</i>	<i>Sí</i>
X_2	<i>Sí</i>	<i>No</i>	<i>No</i>	<i>Sí</i>	<i>Lleno</i>	<i>\$</i>	<i>No</i>	<i>No</i>	<i>Tailandés</i>	<i>30-60</i>	<i>No</i>
X_3	<i>No</i>	<i>Sí</i>	<i>No</i>	<i>No</i>	<i>Algunos</i>	<i>\$</i>	<i>No</i>	<i>No</i>	<i>Hamburg.</i>	<i>0-10</i>	<i>Sí</i>
X_4	<i>Sí</i>	<i>No</i>	<i>Sí</i>	<i>Sí</i>	<i>Lleno</i>	<i>\$</i>	<i>Sí</i>	<i>No</i>	<i>Tailandés</i>	<i>10-30</i>	<i>Sí</i>
X_5	<i>Sí</i>	<i>No</i>	<i>Sí</i>	<i>No</i>	<i>Lleno</i>	<i>\$\$\$</i>	<i>No</i>	<i>Sí</i>	<i>Francés</i>	<i>>60</i>	<i>No</i>
X_6	<i>No</i>	<i>Sí</i>	<i>No</i>	<i>Sí</i>	<i>Algunos</i>	<i>\$\$</i>	<i>Sí</i>	<i>Sí</i>	<i>Italiano</i>	<i>0-10</i>	<i>Sí</i>
X_7	<i>No</i>	<i>Sí</i>	<i>No</i>	<i>No</i>	<i>Ninguno</i>	<i>\$</i>	<i>Sí</i>	<i>No</i>	<i>Hamburg.</i>	<i>0-10</i>	<i>No</i>
X_8	<i>No</i>	<i>No</i>	<i>No</i>	<i>Sí</i>	<i>Algunos</i>	<i>\$\$</i>	<i>Sí</i>	<i>Sí</i>	<i>Tailandés</i>	<i>0-10</i>	<i>Sí</i>
X_9	<i>No</i>	<i>Sí</i>	<i>Sí</i>	<i>No</i>	<i>Lleno</i>	<i>\$</i>	<i>Sí</i>	<i>No</i>	<i>Hamburg.</i>	<i>>60</i>	<i>No</i>
X_{10}	<i>Sí</i>	<i>Sí</i>	<i>Sí</i>	<i>Sí</i>	<i>Lleno</i>	<i>\$\$\$</i>	<i>No</i>	<i>Sí</i>	<i>Italiano</i>	<i>10-30</i>	<i>No</i>
X_{11}	<i>No</i>	<i>No</i>	<i>No</i>	<i>No</i>	<i>Ninguno</i>	<i>\$</i>	<i>No</i>	<i>No</i>	<i>Tailandés</i>	<i>0-10</i>	<i>No</i>
X_{12}	<i>Sí</i>	<i>Sí</i>	<i>Sí</i>	<i>Sí</i>	<i>Lleno</i>	<i>\$</i>	<i>No</i>	<i>No</i>	<i>Hamburg.</i>	<i>30-60</i>	<i>Sí</i>

Figure 1: Ejemplos para el dominio del restaurante

Donde los ejemplos positivos son aquellos en los que la meta *Esperar* es verdadera, y los ejemplos negativos en los que es falsa. El conjunto de ejemplos completo se denomina *conjunto de entrenamiento*.

Esta definición de ejemplo no es la adecuada para este capítulo ya que aquí trabajamos con lógica de predicados, debido a esto en lugar de trabajar con un vector de atributos X , nuestra entrada será una sentencia, donde los atributos se convertirán en predicados unarios, debido a esto ya no podemos pensar en nuestra entrada como vector X más bien como una sentencia a la cual referenciaremos con E_i (entrada). Generalizando el ejemplo

i -ésimo X_i . Por ejemplo en el cuadro anterior, el primer ejemplo se describe a través de la sentencia:

$$E_1 := Alternativa(X_1) \wedge \neg Bar(X_1) \wedge \neg Vier/Sab(X_1) \wedge Hambriento(X_1) \wedge \dots$$

$D_i(X_i)$ es una expresión cualquiera con unico argumento o aridad uno que representará el argumento de la entrada E_i . El valor de salida del objeto E_i puede ser entedida como: La clasificación del objeto dada por la sentencia

$$Esperar(X_1)$$

$Q(X_i)$ es una la notación genérica si el ejemplo es positivo, y $\neg Q(X_i)$ si el ejemplo es negativo. Esta notación generica es una sentencia que representa la salida del objeto E_i o mejor definida sentencia de clasificación o descripción. El conjunto completo de entrenamiento es la conjunción de todas las sentencias de descripción y clasificación.

Aprendizaje inductivo en el marco lógico consiste en encontrar una expresión lógica equivalente al predicado meta Q con el objetivo de clasificar correctamente los ejemplos. Por **expresión lógica equivalente** al predicado meta Q nos referimos a una relación binaria a través del conectivo lógico de la doble implicación (\iff), esta relación no marca una relación fuerte que el lógica se denomina equivalente ya que si el antecedente es falso entonces el consecuente también es falso, y si el consecuente es verdadero el consecuente también los sera, es decir ambos tienen el mismo valor lógico. Por **clasificar correctamente los ejemplos** nos referimos a que dadas las entradas o sentencias E_1, E_2, \dots, E_i la expresión econtrada debe darnos las salidas Q_1, Q_2, \dots, Q_i . Cada **hipótesis** propone una expresión, que denominaremos una **definición candidata** del predicado meta. Usando C_i para representar la definición candidata, cada hipótesis h_i es una sentencia de la forma $\forall x \quad Q(x) \iff C_i(x)$. En este punto conviene “separarnos” un poco de la visión de función en la que veíamos nuestro formulación del aprendizaje y cabe centrarnos en la visión lógica, donde las entradas o E_i , son sentencias que se tomarán como premisas verdaderas y nos servirán como base de conocimiento.

Ejemplo: Una hipótesis h_r pronene una definición candidata C_r , la cual en lenguaje natural es: un predicado meta es verdadero para un objeto si y sólo si se alcanza una de las ramas que llevan a *verdadero*. Formilazando esto en lógica:

$$\begin{aligned} \forall r \text{ Esperar}(r) &\iff \text{Clientes}(r, \text{Algunos}) \\ &\vee \text{Clientes}(r, \text{Lleno}) \wedge \text{Hambriento}(r) \wedge \text{Tipo}(r, \text{Francés}) \\ &\vee \text{Clientes}(r, \text{Lleno}) \wedge \text{Hambriento}(r) \wedge \text{Tipo}(r, \text{Tailandés}) \\ &\quad \wedge \text{Vier/Sab}(r) \\ &\vee \text{Clientes}(r, \text{Lleno}) \wedge \text{Hambriento}(r) \wedge \text{Tipo}(r, \text{Hamburgue.}) \end{aligned}$$

Cada hipótesis predice que un cierto conjunto de ejemplos, es decir aquellos que satisfacen¹ su definición candidata, serán ejemplos del predicado meta, en otras palabras toda $C_j(x)$ de una hipotesis h_j que sea verdadero y que pertenezca al conjunto de ejemplos. Este conjunto se denomina **extensión** del predicado. Dos hipótesis con distintas extensiones son inconsistentes entre sí (\iff). Si tienen la misma extensión, son lógicamente equivalentes.

¹Por satisfacer entendemos toda formula que es verdedara.




Figure 2: \mathcal{A} =Todas las posibles predicciones de C_j . \mathcal{B} =Predicciones positivas de C_j . \mathcal{C} =Predicciones de C_j que forman parte del conjunto de ejemplos.

El espacio de hipótesis H es el conjunto de todas las hipótesis h_1, \dots, h_n que el algoritmo de aprendizaje está diseñado para considerar. Se supone que el algoritmo de aprendizaje considera que una de las hipótesis es correcta:

$$h_1 \vee h_2 \vee h_3 \vee \dots \vee h_n$$

Podemos ir excluyendo las hipótesis que no son *consistentes*, la inconsistencia para un ejemplo puede ocurrir de dos formas:

- Un ejemplo puede ser **falso negativo** para la hipótesis, si la hipótesis afirma que debe ser negativo pero en realidad es positivo.
- Un ejemplo puede ser un **falso positivo** para la hipótesis, si la hipótesis afirma que debe ser positivo pero en realidad es negativo.


Entonces un ejemplo puede ser inconsistente con una hipótesis, podemos aprovechar esto para ir eliminando una o más hipótesis.

Por lo tanto, podemos caracterizar el aprendizaje inductivo en un marco lógico como un proceso de eliminación gradual de las hipótesis que son inconsistentes con los ejemplos, reduciendo así las probabilidades. Sin embargo pueden existir espacios de hipótesis enormes e incluso infinitos por eso describimos dos enfoques que encuentran hipótesis lógicamente con mucho menos esfuerzo.

2.1 Búsqueda mejor-hipótesis-actual

La idea de la búsqueda mejor-hipótesis-actual es mantener una única hipótesis, y ajustarla cuando llegan nuevos ejemplos para que se mantenga la consistencia.

Supongamos que tenemos una hipótesis h_r cualquiera, y hasta el momento todos los ejemplos son consistentes. Donde el rectángulo es la extensión de h_r . Entonces surge un ejemplo falso negativo, por lo tanto ese ejemplo debería formar parte de la extensión. La extensión debe *aumentarse* e incluirlo. A esto se denomina **generalización**. Sin embargo surge otro ejemplo falso positivo, por lo tanto ese ejemplo no debería formar parte de la extensión. La extensión debe *reducirse* y excluirla. A esto se denomina **especialización**. Ya en el algoritmo, tanto la especificación y generalización deben



comprobar la consistencia con el resto de ejemplos.

```

function CURRENT-BEST-LEARNING(examples, h) returns a hypothesis or fail
  if examples is empty then
    return h
  e ← FIRST(examples)
  if e is consistent with h then
    return CURRENT-BEST-LEARNING(REST(examples), h)
  else if e is a false positive for h then
    for each h' in specializations of h consistent with examples seen so far do
      h'' ← CURRENT-BEST-LEARNING(REST(examples), h')
      if h'' ≠ fail then return h''
  else if e is a false negative for h then
    for each h' in generalizations of h consistent with examples seen so far do
      h'' ← CURRENT-BEST-LEARNING(REST(examples), h')
      if h'' ≠ fail then return h''
  return fail

```

Figure 3: Busca una hipótesis consistente que ajuste todos los ejemplos.

Entonces definimos la generalización y especialización como operaciones que cambian la *extensión* de nuestra hipótesis. Ahora necesitamos implementar operaciones sintácticas de manera exacta que modifiquen la definición candidata (C_j) asociada con la hipótesis. Esto se realiza observando que la generalización y la especialización son **realciones lógicas entre hipótesis**. Si la hipótesis h_1 , con la definición C_1 , es una generalización de la hipótesis h_2 con la definición C_2 , entonces debemos tener

$$\forall x \quad C_2(x) \Rightarrow C_1(x)$$

Por lo tanto, para construir una generalización de h_2 , necesitamos la definición C_1 que sea una implicación lógica de C_2 .

Existen varias operaciones de generalización, pero el que usaremos será la **omisión de condiciones** (dropping conditions). Para especializar podemos **agregar condiciones** o **eliminar disyunciones** de una definición disyuntiva.

Ejemplo: Usando la tabla de la figura 1, iremos construyendo nuestra hipótesis.

- El primer ejemplo X_1 es positivo. $Alternativa(X_1)$ es verdadero, así que la hipótesis inicial será

$$h_1 : \forall x \quad Esperar(x) \Leftrightarrow Alternativa(x)$$

- El segundo ejemplo X_2 es negativo. h_1 lo predice como positivo, así que es un falso positivo. Por ello, tenemos que especializar h_1 . Se puede hacer añadiendo una condición extra que rehace X_2 . Una posibilidad es

$$h_2 : \forall x \quad Esperar(x) \Leftrightarrow Alternativa(x) \wedge Clientes(x, Algunos)$$

- El tercer ejemplo X_3 es positivo. h_2 lo predice como negativo, luego es un falso negativo. Por ello, necesitamos generalizar h_2 . Eliminamos la condición $Alternativa$, resultando

$$h_3 : \forall x \quad Esperar(x) \Leftrightarrow Clientes(x, Algunos)$$

- El cuarto ejemplo X_4 es positivo. h_3 lo predice como negativo, luego es un falso negativo. Por ello, necesitamos generalizar. No podemos eliminar la condición de $Clientes$, ya que obtendríamos una hipótesis que incluye a todos los ejemplos, que sería inconsistente con X_2 . Una posibilidad es añadir una disyunción:

$$h_4 : \forall x \quad Esperar(x) \Leftrightarrow Clientes(x, Algunos) \vee (Clientes(x, Lleno) \wedge Vier/Sab(x))$$

La hipótesis ya está comenzando a parecer razonable. Obviamente, existen otras posibilidades consistentes con los cuatro primeros ejemplos; aquí están otras dos:

$$h'_4 : \forall x \quad Esperar(x) \Leftrightarrow \neg TiempoEsperaEstimado(x, 30 - 60)$$

$$h''_4 : \forall x \quad Esperar(x) \Leftrightarrow Clientes(x, Algunos)$$

$$\vee (Clientes(x, Lleno) \wedge TiempoEsperaEstimado(x, 10 - 30))$$

Este tipo de algoritmo es muy caro computacionalmente debido al *backtracking*, se dice que es doblemente exponencial.

3 Conocimiento en el aprendizaje

3.1 Aprendizaje con conocimiento básico

El aprendizaje inductivo se basa en el descubrimiento de patrones a partir de ejemplos.

El conocimiento a priori es aquel que, en algún sentido importante, es independiente de la experiencia. Para entender el papel del conocimiento a priori, necesitamos hablar de las relaciones lógicas entre hipótesis, descripciones de ejemplos y clasificaciones.

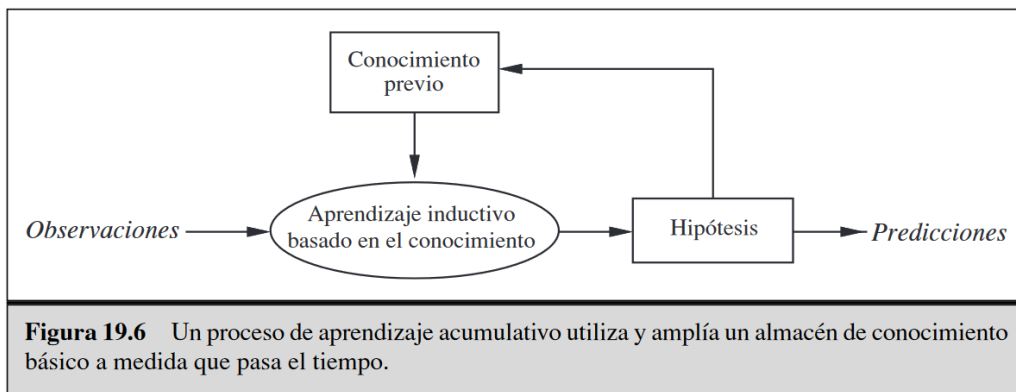
Descripciones: Conjunción de todas las descripciones de los ejemplos del conjunto de entrenamiento.

$$Hipótesis \wedge Descripciones \models Clasificaciones$$

Clasificaciones: Conjunción de todas las clasificaciones de los ejemplos. De este modo, las Hipótesis que “explican las observaciones” deben satisfacer la siguiente propiedad:

Esta relación se denomina restricción, donde Hipótesis es lo “desconocido”. El objetivo del aprendizaje inductivo puro es resolver esta restricción, donde Hipótesis se obtiene a partir de algún espacio de hipótesis predefinido.

Para construir un *agente de aprendizaje autónomo que utilice conocimiento básico*, el agente debe contar con algún método para obtener el conocimiento básico, para que este conocimiento se pueda utilizar en los nuevos episodios de aprendizaje. Este método también debe ser en sí mismo un proceso de aprendizaje, la historia de la vida del agente estará caracterizada por un desarrollo acumulativo o incremental.



3.2 Ejemplos de aprendizaje con conocimiento básico

3.2.1 Aprendizaje basado en explicaciones (EBL)

Ejemplo: Un hombre primitivo, está asando un lagarto en una vara. Es observado por una multitud asombrada de sus contemporáneos menos intelectuales, quienes han venido utilizando sus manos desnudas para mantener sus provisiones sobre el fuego. Esta instructiva experiencia es suficiente para convencer a los observadores de un principio general para cocinar sin dolor.

Tipo de restricción: El hombre primitivo generaliza explicando el éxito de la vara: ésta soporta al lagarto, manteniendo así la mano lejos del fuego. A partir de esta explicación, infiere una *regla general*: que cualquier objeto largo, rígido y puntiagudo sirve para asar alimentos pequeños y ligeros.

Este tipo de proceso de generalización es denominado aprendizaje basado en explicaciones, o EBL (Explanation Based Learning). La regla general se deduce lógicamente del conocimiento básico que posee el hombre primitivo. Por lo tanto, las restricciones que se satisfacen por el EBL son las siguientes:

$$Hipótesis \wedge Descripciones \models Clasificaciones$$

$$ConocimientoBásico \models Hipótesis$$

EBL necesita que exista suficiente conocimiento básico como para explicar la Hipótesis, que en realidad explica las observaciones, por tanto, realmente el agente no aprende nada

nuevo del ejemplo. El agente podría haber derivado el ejemplo de lo que ya sabía, aunque esto requiriera una cantidad muy elevada de computación. EBL no se considera como un método para convertir los primeros principios de las teorías en conocimiento útil de propósito específico.

3.2.2 Aprendizaje basado en Relevancia (RBL)

Ejemplo: Un turista va a Brasil y conoce a su primera persona brasileña. Al escucharle hablar en portugués, inmediatamente concluirá que los brasileños hablan en portugués, aunque al descubrir que su nombre es Fernando no concluirá que todos los brasileños se llaman Fernando.

En este caso, el conocimiento a priori relevante es que, en cualquier país, la mayoría de la gente habla el mismo idioma; por otro lado, no se asume que Fernando sea el nombre de todos los brasileños, porque este tipo de regularidad no se verifica para los nombres.

En este caso, el Conocimiento Básico a priori se refiere a la relevancia que tiene un conjunto de características sobre el predicado meta. Este conocimiento, junto con las observaciones, permite al agente inferir una nueva regla general que explica las observaciones:

$$\begin{aligned} \text{Hipótesis} \wedge \text{Descripciones} &\models \text{Clasificaciones} \\ \text{Hipótesis} \wedge \text{Descripciones} \wedge \text{Clasificaciones} &\models \text{Hipótesis} \end{aligned}$$

Como el RBL no hace uso del contenido de las observaciones, no produce hipótesis que vayan más allá del contenido lógico del conocimiento básico y de las observaciones. Es un método de aprendizaje deductivo, y por sí mismo no puede justificar la creación de nuevo conocimiento sin un conocimiento inicial de partida.

3.2.3 Aprendizaje inductivo basado en el conocimiento (Algoritmo KBIL)

Ejemplo: Un estudiante de Medicina sabe realizar diagnósticos sofisticados, pero es ignorante respecto a farmacología, está observando la consulta entre un paciente y un experto. Después de una serie de preguntas y respuestas, el experto dice al paciente que tome un determinado antibiótico. El estudiante de medicina inferirá la regla general sobre qué antibiótico particular es efectivo para un tipo de infección determinado.

Se asume que el conocimiento a priori del estudiante es suficiente para inferir la enfermedad (D) del paciente a partir de los síntomas. Sin embargo, esto no es suficiente para explicar el hecho de que el doctor prescribe una medicina concreta (M). El estudiante necesita obtener otra regla: que M , generalmente, es una medicina efectiva contra la enfermedad D . Dada esta regla, y el conocimiento a priori con el que cuenta el estudiante, éste puede explicar por qué el experto prescribe M en ese caso particular. Podemos generalizar este ejemplo para proponer la restricción:

$$\text{ConocimientoBásico} \wedge \text{Hipótesis} \wedge \text{Descripciones} \models \text{Clasificaciones} \quad (19.5)$$

4 Aprendizaje basado en explicaciones

El aprendizaje basado en explicaciones es un método para extraer reglas generales a partir de observaciones particulares. Supongamos que estamos aprendiendo a integrar.



Figura 4.1: Entradas y salidas de un método EBL

Sabemos las reglas de integración, la tabla de integrales inmediatas y los métodos que podemos usar para resolverlas. Al principio, cuando nos dan una integral para resolver, vamos probando métodos hasta encontrar uno que nos de la solución de forma sencilla. Esto es, si decidimos aplicar un método y este nos lleva a una expresión más complicada, lo descartamos y probamos con otro. A medida que aumentamos nuestra experiencia en la resolución de integrales sabremos a simple vista cuál es el método más apropiado para obtener la solución. Un método EBL puede asociarse a un sistema de resolución de problemas de manera que nos permitirá aprender reglas de control que mejorarán su eficiencia

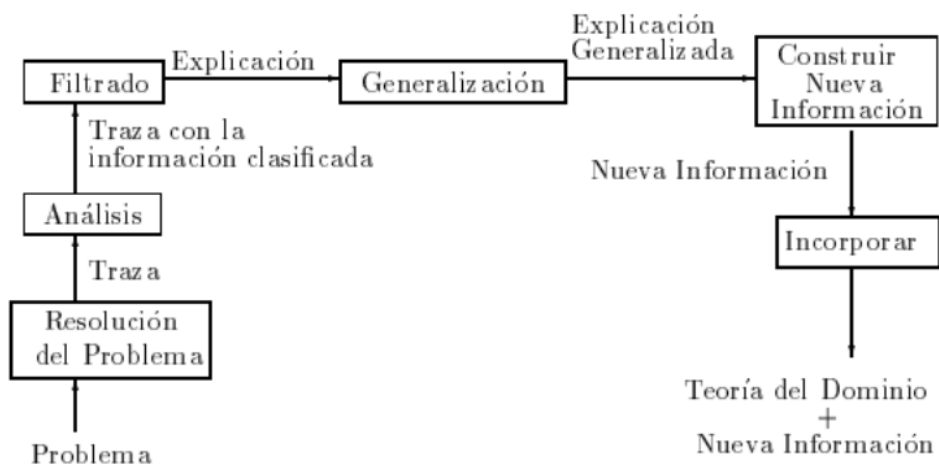


Figura 4.2: Descomposición de un método EBL

4.1 Técnicas de la memorización

La técnica de memorización ha sido extensamente utilizada en informática para acelerar los programas guardando los resultados de la computación. La idea básica de las funciones memo es acumular una base de datos de pares *entrada/salida*; cuando se hace una llamada a la función, ésta, en primer lugar, comprueba la base de datos para ver si se puede evitar que la resolución del problema parta de cero.

4.2 Extracción de reglas generales a partir de ejemplos:

La idea en la que se basa EBL consiste en construir, en primer lugar, una explicación de la observación, utilizando conocimiento a priori, y posteriormente, establecer una definición de la clase de casos para los que se puede utilizar la misma estructura de explicación. Esta definición proporciona las bases para una regla que cubra todos los casos en la clase. La “explicación” puede ser una prueba lógica, aunque de forma más general, puede ser cualquier proceso de razonamiento o de resolución de problemas cuyos pasos estén bien definidos. La clave es ser capaz de identificar las condiciones necesarias para que los mismos pasos se puedan aplicar a otro caso.

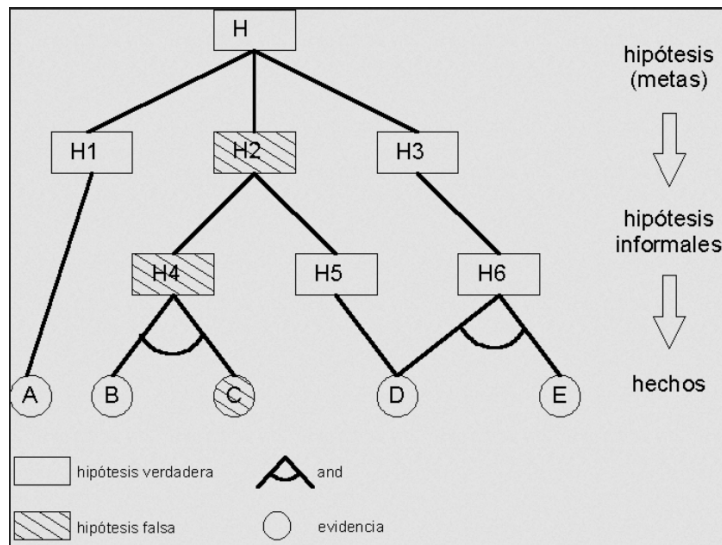
4.3 Encadenamiento hacia atrás

El proceso de desarrollo de un Sistema basado en encadenamiento hacia atrás está dado de la siguiente manera:

- Se comienza con una meta para probar
- Se inspecciona la memoria de trabajo para ver si la meta ha sido previamente probada
- En caso de que no se haya probado, el sistema busca en sus reglas para ver si una o más tienen esta meta en su parte del *THEN*, este tipo de regla es llamada regla meta.
- El sistema ve si las premisas de las reglas meta están listadas en la memoria de trabajo, las premisas no listadas se tornan nuevas metas o subtemas para ser probadas.
- Este proceso continúa de manera recursiva hasta que el sistema encuentra una premisa que no es soportada por ninguna regla, llamada primitiva (premisa de una regla que no es concluida por ninguna regla)
- Cuando una primitiva es encontrada, el sistema pregunta al usuario información acerca de esta primitiva, entonces el sistema usa esta información para ayudar a probar los subtemas y la meta original

En el encadenamiento hacia atrás, el orden a probar la hipótesis h deberá de probarse al menos una de las hipótesis intermedias. Se observa que el diagrama, en este caso se describe como un diagrama *AND/OR* para indicar que en algún caso, tal como h_2 todas las hipótesis de nivel inferior deben estar presentes para sostener h_2 .

En otros casos, tal como la hipótesis de nivel superior h solo es necesario una hipótesis de nivel inferior para que se verifique. En el encadenamiento hacia atrás, el sistema, por lo general, obtendrá evidencia del usuario, con el fin de probar o no la hipótesis, lo que contrasta con el sistema de encadenamiento hacia adelante, en el que todos los hechos relevantes se conocen por lo general con antelación.



4.3.1 Ejemplo del ecadenamiento hacia atrás

Supongamos que un paciente va al doctor, el doctor luego de escuchar el problema del paciente creó que tiene una infección de garganta. Ahora bien veremos como un sistema experto basado en reglas de encadenamiento hacia atrás puede solucionar este problema.

4.4 Proceso básico de EBL

El proceso básico de EBL funciona de la siguiente forma:

1. Dado un ejemplo, se construye una prueba para el predicado meta que se aplica al ejemplo, utilizando el conocimiento básico disponible.
2. En paralelo, se construye un árbol de prueba generalizado para la meta variabilizada, utilizando los mismos pasos de inferencia que en la prueba original.
3. Se construye una nueva regla cuya parte izquierda está formada por las hojas del árbol de prueba y cuya parte derecha es la meta variabilizada (después de aplicar las asignaciones necesarias de la prueba generalizada).
4. Se eliminan todas las condiciones que son verdaderas independientemente de los valores de las variables de la meta.

5 Aprendizaje basado en información relevante

Parece que nuestro turista en Brasil es capaz de hacer una generalización segura sobre el idioma que hablan otros brasileños.

Su conocimiento básico autoriza la inferencia: la gente del mismo país (normalmente) habla el mismo idioma. Esto se puede expresar en lógica de primer orden de la siguiente manera:

$$Nacionalidad(x, n) \wedge Nacionalidad(y, n) \wedge Idioma(x, l) \Rightarrow Idioma(y, l)$$

No es difícil demostrar que a partir de esta sentencia y de la observación,

$$Nacionalidad(Fernando, Brasil) \wedge Idioma(Fernando, Portugues)$$

Se deduce la siguiente conclusión:

$$Nacionalidad(x, Brasil) \wedge Idioma(x, Portugues)$$

Las sentencias anteriores expresan una forma estricta de relevancia: dada una nacionalidad, el idioma queda totalmente determinado.

Estas sentencias se denominan dependencias funcionales o determinaciones. Son tan comunes en algunos tipos de aplicaciones, que se utiliza una sintaxis especial para escribirlas. Adoptaremos la notación de Davies (1985):

$$Nacionalidad(x, n) \succ Idioma(x, l)$$

Esto es simplemente el azúcar sintáctico al que ya estamos acostumbrados, pero deja claro que la determinación es realmente una relación entre los predicados: la nacionalidad determina el lenguaje.

Las propiedades relevantes que determinan la conductancia y la densidad se pueden expresar de una forma similar:

$$Material(x, m) \wedge Temperatura(x, t) \succ Conductancia(x, p);$$

$$Material(x, m) \wedge Temperatura(x, t) \succ Densidad(x, d)$$

5.1 Determinar el espacio de hipótesis

Aunque las determinaciones autorizan la obtención de conclusiones generales para todos los brasileños, o para todas las piezas de cobre a una temperatura dada, por supuesto, no pueden dar lugar a una teoría de predicción general para todas las nacionalidades, o para todas las temperaturas y materiales, a partir de un simple ejemplo.

Se puede decir que su principal efecto es que limitan el espacio de hipótesis que el agente de aprendizaje necesita considerar. Por ejemplo, para predecir la conductancia, se necesita considerar únicamente el material y la temperatura, y se puede ignorar la masa, el propietario, el día de la semana, el presidente actual, etc. Desde luego, las hipótesis pueden incluir términos que vienen determinados por el material y la temperatura, como la estructura molecular, la energía térmica, o la densidad de electrones libres. Las determinaciones especifican un vocabulario básico suficiente para construir hipótesis relativas al predicado principal. Esta sentencia se puede demostrar mostrando que una determinación dada es lógicamente equivalente a una sentencia en la que el predicado principal es uno de los elementos del conjunto de todas las definiciones que se pueden expresar utilizando los predicados de la parte derecha de la determinación.

5.2 Aprender y utilizar información relevante

Como ya comentamos en la introducción de este capítulo, el conocimiento a priori es muy útil para el aprendizaje, pero también tiene que aprenderse.

Por lo tanto, para conocer completamente el aprendizaje basado en información relevante, debemos proporcionar un algoritmo de aprendizaje para determinaciones. El algoritmo de aprendizaje que vamos a presentar se basa en un intento sencillo para encontrar la determinación más simple que es consistente con las observaciones. Una determinación $P \succ Q$ indica que si algunos ejemplos encajan con P , también deben encajar con Q . Por lo tanto, una determinación es consistente con un conjunto de ejemplos, si cada par que encaja con los predicados de la parte izquierda también encaja con el predicado principal, es decir, tiene la misma clasificación. Por ejemplo, suponga que tenemos los siguientes ejemplos, relativos a medidas de conductancia en unas muestras de material:

Muestra	Masa	Temperatura	Material	Tamaño	Conductancia
S1	12	26	Cobre	3	0,59
S1	12	100	Cobre	3	0,57
S2	24	26	Cobre	6	0,59
S3	12	26	Plomo	2	0,05
S3	12	100	Plomo	2	0,04
S4	24	26	Plomo	4	0,05

La determinación consistente mínima es

$$Material \wedge Temperatura \succ Conductancia$$

Existe una determinación no mínima, pero consistente:

$$Masa \wedge Tamaño \wedge Temperatura \succ Conductancia$$

Es consistente con los ejemplos porque la masa y el tamaño determinan la densidad, y en nuestro conjunto de datos no tenemos dos materiales diferentes con la misma densidad. Como es usual, necesitaríamos una muestra más grande para eliminar una hipótesis casi correcta.

función DET-CONSISTENTE-MINIMA(E, A) devuelve un conjunto de atributos

entrada: E , un conjunto de ejemplos

A , un conjunto de atributos de tamaño n

para $i = 0, \dots, n$ **hacer**

para cada subconjunto A_i de A de tamaño i **hacer**

si DET-CONSISTENTE?(A_i, E) **entonces devolver** A_i

función DET-CONSISTENTE? (A, E) devuelve un valor de verdad

entrada: A , un conjunto de atributos

E , un conjunto de ejemplos

variables locales: H , una tabla *hash*

para cada ejemplo e **en** E **hacer**

si algún ejemplo de H tiene los mismos valores que e para los atributos A , pero diferente clasificación **entonces devolver** falso

guardar la clase de e en H , indexada por los valores para los atributos A del ejemplo e

devolver verdadero

6 Programación lógica inductiva

Combina los métodos de inducción con la potencia de las representaciones de primer orden.

¿Por qué es tan popular?

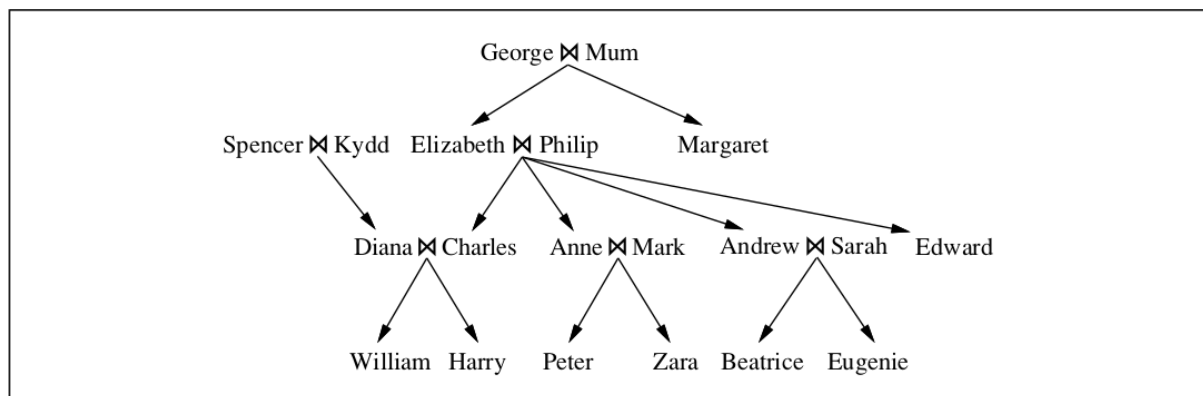
- Ofrece un enfoque riguroso al problema de aprendizaje inductivo basado en el conocimiento.
- Ofrece algoritmos completos para inducir teorías de primer orden generales, a partir de los ejemplos.
- Produce hipótesis que son (relativamente) fáciles de entender por humanos.

Ejemplo: Tenemos el problema general de inducción basado en el conocimiento cuyo fin es “resolver” la restricción.

$$\text{ConocimientoBásico} \wedge \text{Hipótesis} \wedge \text{Descripciones} \models \text{Clasificaciones}$$

Para la **Hipótesis** desconocida, dados el **ConocimientoBásico** y los ejemplos descritos por las **Descripciones** y las **Clasificaciones**.

Para ilustrar esto, usaremos el problema de aprendizaje de relaciones familiares a partir de ejemplos. Las **Descripciones** consistirán en un árbol genealógico extendido,



descrito en términos de Madre, Padre, la relación CasadoCon y las propiedades Hombre y Mujer. Las sentencias en **Clasificaciones** dependen del concepto objetivo que

<i>Padre(Philip, Charles)</i>	<i>Padre(Philip, Anne)</i>	...
<i>Madre(Mum, Margaret)</i>	<i>Madre(Mum, Elizabeth)</i>	...
<i>CasadoCon(Diana, Charles)</i>	<i>CasadoCon(Elizabeth, Philip)</i>	...
<i>Hombre(Philip)</i>	<i>Hombre(Charles)</i>	...
<i>Mujer(Beatrice)</i>	<i>Mujer(Margaret)</i>	...

está siendo aprendido. Podríamos querer aprender *Abuelo/a*, *Cuñado*, o **Ancestro**, por ejemplo. Podríamos aprender a partir de un subconjunto de este conjunto completo.

<i>Abuelo/a(Mum, Charles)</i>	<i>Abuelo/a(Elizabeth, Beatrice)</i>	<i>...</i>
\neg <i>Abuelo/a(Mum, Harry)</i>	\neg <i>Abuelo/a(Spencer, Peter)</i>	<i>...</i>

El objetivo de un programa de aprendizaje inductivo es proponer un conjunto de sentencias para la Hipótesis, tal que la restricción se satisfaga.

Suponga, por el momento, que el agente no tiene conocimiento básico: ConocimientoBásico es vacío. Entonces una posible solución para la Hipótesis es la siguiente: